

Estimation dans un problème inverse linéaire à variables cachées

Vraisemblance, algorithme EM et analyse de l'erreur

Arthur Conche Abdel Niang

Année universitaire 2025–2026

M1 MMAS Université Paris Cité

Encadrant : Camille Pouchol

Motivation et modèle

Cas de référence et log-vraisemblance

Algorithmes d'optimisation

Analyse de l'erreur

Régularisation et extension 2D

Conclusion

Motivation et modèle

Contexte : la cryo-microscopie électronique


Objectif biologique. Reconstruire la structure 3D de macromolécules (protéines, virus...) à partir de milliers de projections 2D bruitées.

Prix Nobel de Chimie 2017 Dubochet, Frank, Henderson.

Défi mathématique.

- Chaque copie est figée dans une **orientation aléatoire inconnue** $Z_i \in SO(3)$.
- On observe uniquement $Y_i = A_{Z_i}\theta + \sigma E_i$.
- Il faut reconstruire θ sans connaître les Z_i .

⇒ Problème inverse linéaire à **variables cachées**.



Projections 2D d'une molécule selon des orientations aléatoires inconnues.

Modèle (M)

$$Y_i = A_{Z_i}\theta + \sigma E_i, \quad i = 1, \dots, n,$$

- $\theta \in E \subset \mathbb{R}^d$ signal inconnu,
- $Z_i \stackrel{\text{i.i.d.}}{\sim} f_Z$ variable cachée (transformation),
- $A_z \in \mathcal{L}(E, \mathbb{R}^p)$ opérateur paramétré par z ,
- $E_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \text{Id}_p)$ bruit.

Deux cas d'application étudiés :


Cas 1 Translations 1D

$Z_i \sim \text{Unif}([0, 2\pi[)$, $(A_z\theta)_j = \theta(x_j - z)$,
espace E : polynômes trigonométriques de
degré $\leq \frac{d-1}{2}$.

Cas 2 Rotations + projections 2D

$Z_i \sim \text{Unif}([0, 2\pi[)$, $A_z = \text{ev}_{\text{grille}} \circ P \circ R_z$
(rotation + transformée de Radon). Modèle
jouet de la cryo-EM.

Données simulées Cas 1



Cas de référence et log-vraisemblance

Cas de référence : modèle sans variables cachées

Modèle simplifié : $Y_i = A\theta + \sigma E_i$ (A fixe).

Estimateur MV (moindres carrés) :


$$\hat{\theta}_n = (A^\top A)^{-1} A^\top \bar{Y}_n, \quad \bar{Y}_n = \frac{1}{n} \sum_i Y_i.$$

Erreur quadratique exacte :

$$\varepsilon_n^2 = \frac{\sigma^2}{n} \text{Tr}((A^\top A)^{-1})$$

Deux enseignements clés :

- L'erreur décroît en $1/\sqrt{n}$ (loi des grands nombres).
- La formule ε_n^2 sert de **référence oracle** pour mesurer le surcoût des variables cachées.



Signal θ (bleu) et quelques observations Y_i (gris).

Log-vraisemblance marginale et non-identifiabilité

Log-vraisemblance marginale (intégration sur Z) :

$$\ell_n(\theta) = \sum_{i=1}^n \log \int_{\mathcal{Z}} \exp\left(-\frac{\|Y_i - A_z \theta\|^2}{2\sigma^2}\right) f_Z(z) d\mu(z) + \text{cste.}$$

Propriétés analytiques.

- $\ell_n \in C^\infty$ (dérivation sous l'intégrale).
- **Non concave** en général $\Rightarrow$ optima locaux.
- Coercive $\Rightarrow$ au moins un maximum global.

Non-identifiabilité (Cas 1). Le groupe des translations est un **groupe d'invariance** :

$$\ell_n(\tau_a \theta) = \ell_n(\theta) \quad \forall a \in [0, 2\pi[.$$

On mesure l'erreur par :

$$\varepsilon_n(\sigma) = \inf_{\theta} \left\| \tau_a \hat{\theta}_n - \theta \right\| / \|\theta\|.$$

Poids a posteriori

$$w_{i,z}(\theta) = \frac{f_Z(z) e^{-\frac{\|Y_i - A_z \theta\|^2}{2\sigma^2}}}{\int f_Z(z') e^{-\frac{\|Y_i - A_{z'} \theta\|^2}{2\sigma^2}} dz'}$$

Ces poids encodent la distribution a posteriori de $Z_i | Y_i$.

Poids a posteriori $w_{i,z}(\theta)$

Origine (formule de Bayes discrétisée). Conditionnellement à $Z_i = z$, on a $Y_i \sim \mathcal{N}(A_z \theta, \sigma^2 \text{Id}_p)$, et $Z_i \sim f_Z$. La loi a posteriori de Z_i sachant Y_i a pour densité :

$$p(z \mid Y_i; \theta) = \frac{f_Z(z) \exp\left(-\frac{\|Y_i - A_z \theta\|^2}{2\sigma^2}\right)}{\int_{\mathcal{Z}} f_Z(z') \exp\left(-\frac{\|Y_i - A_{z'} \theta\|^2}{2\sigma^2}\right) d\mu(z')} =: w_{i,z}(\theta).$$

Propriétés

- $w_{i,z}(\theta) \geq 0$ et $\int_{\mathcal{Z}} w_{i,z}(\theta) d\mu(z) = 1$: c'est une **densité de probabilité** en z .
- Dépend de θ : structure de **point fixe** exploitée par l'EM.

Rôle dans les algorithmes

- **Gradient :**
 $\nabla_{\theta} \ell_n = \frac{1}{\sigma^2} \sum_i \int w_{i,z} A_z^{\top} (Y_i - A_z \theta) d\mu(z)$
- **EM, étape E :** calcul explicite de $w_{i,z}(\theta^{(k)})$.
- **EM, étape M :**
 $M^{(k)} = \sum_i \int w_{i,z}(\theta^{(k)}) A_z^{\top} A_z d\mu(z).$

Algorithmes d'optimisation

Gradient (Proposition 3.3) :

$$\nabla_{\theta} \ell_n(\theta) = \frac{1}{\sigma^2} \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta) A_z^{\top} (Y_i - A_z \theta) d\mu(z).$$

Interprétation : *espérance pondérée des résidus* par rapport à la loi a posteriori.

Itération avec règle d'Armijo :

$$\theta^{(k+1)} = \theta^{(k)} + \eta_k \nabla_{\theta} \ell_n(\theta^{(k)}),$$

où η_k est choisi par recherche linéaire (condition d'Armijo) pour garantir $\ell_n(\theta^{(k+1)}) \geq \ell_n(\theta^{(k)}) + c \eta_k \|\nabla \ell_n\|^2$.

Limites

Sensible au pas initial η_0 , convergence lente vers un optimum local.

Algorithme EM

Idée : si les Z_i étaient observés, la log-vraisemblance complète $\ell_n^c(\theta; Z)$ est quadratique en θ .

Étape E Calculer les poids :

$$w_{i,z}(\theta^{(k)}) \quad \forall i, z.$$

Étape M Résoudre le système linéaire :

$$M^{(k)} \theta^{(k+1)} = b^{(k)},$$

$$M^{(k)} = \sum_i \int w_{i,z}(\theta^{(k)}) A_z^\top A_z d\mu(z),$$

$$b^{(k)} = \sum_i \int w_{i,z}(\theta^{(k)}) A_z^\top Y_i d\mu(z).$$

Propriétés

Monotonie (Prop. 4.1) :

$$\ell_n(\theta^{(k+1)}) \geq \ell_n(\theta^{(k)})$$

par l'inégalité de Jensen.

Points d'adhérence : tout point limite est un point stationnaire de ℓ_n (Thm. 4.3).

Coût dominant : étape E en $O(n \cdot n_z \cdot pd)$, étape M en $O(d^3)$.


Comparaison des deux algorithmes

	Descente de gradient	EM
Monotonie	règle d'Armijo	garantie théorique
Étape clé	calcul du gradient	système linéaire $d \times d$
Coût/itération	$O(n \cdot n_z \cdot pd)$	$O(n \cdot n_z \cdot pd + d^3)$
Sensibilité	pas initial η_0	initialisation
Convergence	lente (1 ^{er} ordre)	plus robuste

En pratique (Cas 1) : l'EM est lancé avec **20 initialisations aléatoires** par répétition Monte-Carlo pour limiter le piège des optima locaux.

Analyse de l'erreur

Erreur en fonction de n : plateau algorithmique




Protocole : $p = 32$, $d = 7$, $n_z = 64$,
 $M = 15$ répétitions Monte-Carlo.

Observations clés.

- Référence oracle : $\varepsilon_n \propto n^{-1/2}$ (attendu).
- Pour $\sigma \in \{0.3, 0.5, 1.0\}$: **plateau dès $n \approx 50$** , l'EM ne bénéficie plus de données supplémentaires.
- Facteur de surcoût : de $1.5\times$ ($n = 10$) à $4.5\times$ ($n = 200$).
- **Goulot algorithmique**, pas statistique : convergence vers un optimum local de ℓ_n non concave.
- $\sigma = 0.1$: poids quasi-Diracs, l'EM est piégé et l'erreur est paradoxalement

Erreur en fonction de σ : courbe en U



Trois régimes.

1. Faible bruit ($\sigma \lesssim 0.1$) poids concentrés.

Poids a posteriori $\approx$ Diracs, landscape très accidenté, EM piégé dans des optima locaux.

$\Rightarrow$ **erreur élevée.**

2. Bruit modéré ($\sigma \in [0.2, 0.5]$) régime optimal. Poids suffisamment diffus, landscape régulier. $\Rightarrow$ **erreur minimale.**

3. Bruit élevé ($\sigma \gtrsim 1$) poids uniformes.

Les observations n'informent plus sur θ . $\Rightarrow$ **erreur croissante.**

La courbe en U traduit un compromis entre *identifiabilité* et *explorabilité* du landscape.

Régularisation et extension 2D

Régularisation Cas 2 mal posé

Pourquoi régulariser ? En Cas 2, $A_z = \text{ev} \circ P \circ R_z$ est un opérateur intégral : $A_z^\top A_z$ a un spectre $\sim |\xi|^{-1}$ (filtre passe-bas), $M^{(k)}$ est **mal conditionné**.

Pénalité générale : $\ell_n^{\text{reg}}(\theta) = \ell_n(\theta) - \lambda R(\theta)$.

Tikhonov (ℓ_2)

$$R(\theta) = \frac{1}{2} \|\theta\|^2$$

M-step : système linéaire

$$(M^{(k)} + \lambda \sigma^2 I) \theta^{(k+1)} = b^{(k)}$$

Restaure le conditionnement.

Pénalité ℓ_1

$$R(\theta) = \|\theta\|_1$$

M-step non lisse, résolu par ISTA/FISTA (seuillage doux). Favorise la parcimonie.


Variation totale

$$R(\theta) = \text{TV}(\theta)$$

Préserve les discontinuités (bords nets). Pertinent pour la reconstruction d'images.


Choix de λ : validation croisée k -fold, courbe en L, GCV.

Cas 1 erreur vs λ :



$n = 50, \sigma = 0.3, M = 20$ répétitions. $M^{(k)} \approx p \text{Id}$ (bien conditionné) : la régularisation n'améliore pas sensiblement l'erreur en Cas 1.

Cas 2 reconstruction oracle ($K = 40$ angles, $\sigma = 0.05$) :



Gauche : image vraie. **Centre** : sans régularisation erreur 33%. **Droite** : Tikhonov $\lambda = 150$ erreur 7%. La régularisation est **indispensable** en Cas 2.

Théorème 7.2 Fourier Slice Theorem

Soit $\theta \in L^1(\mathbb{R}^2) \cap L^2(\mathbb{R}^2)$, $\hat{\theta}$ sa TF 2D, et $z \in [0, \pi[$. Alors :

$$\widehat{P(R_z \theta)}(\xi) = \hat{\theta}(\xi \cos z, -\xi \sin z), \quad \xi \in \mathbb{R}.$$

Interprétation. Quand ξ parcourt $\mathbb{R}$,
($\xi \cos z, -\xi \sin z$) décrit la **droite radiale d'angle z**
dans le plan de Fourier.

Conséquences.

- K angles $\Rightarrow K$ tranches radiales : base de la reconstruction tomographique.
- Spectre de $A_z^\top A_z \sim |\xi|^{-1} \Rightarrow M^{(k)}$ **mal conditionné** en Cas 2.
- Justifie l'indispensabilité de la régularisation.

Esquisse de preuve

Par Fubini sur $\widehat{P(R_z \theta)}(\xi)$, le ch. de variable $(u, v)^\top = R_{-z}(x, y)^\top$ (jacobien 1) donne directement $\hat{\theta}(\xi \cos z, -\xi \sin z)$.

Comparaison structurelle Cas 1 / Cas 2

	Cas 1 (translations 1D)	Cas 2 (rotations + proj. 2D)
Structure de $A_z^\top A_z$	$p \text{Id}_d$ (optimal)	spectre $\sim \xi ^{-1}$ (mal conditionné)
Cond. de $M^{(k)}$	1 (M-step triviale)	$\rightarrow \infty$ avec la résolution
Régularisation	optionnelle	indispensable
Groupe d'invariance de ℓ_n	$\mathbb{R}/2\pi\mathbb{Z}$ (translations)	$O(2)$ (rotations + chiralité)
Métrique d'erreur	$\inf_a \left\ \tau_a \hat{\theta} - \theta \right\ / \ \theta\ $	$\inf_a \left\ R_a \hat{\theta} - \theta \right\ / \ \theta\ $

Conclusion

Bilan.


- Modèle jouet rigoureux de la cryo-EM, analysé de bout en bout.
- Deux algorithmes comparés : descente de gradient et EM (robustesse, monotonie garantie).
- Phénomène central : **plateau algorithmique** le goulot est l'optimisation (non-concavité de ℓ_n), pas la statistique.
- Régularisation Tikhonov : **indispensable en Cas 2**, divisé l'erreur par ~ 5 sur l'exemple oracle.

Perspectives.

- **Bornes minimax** pour $\varepsilon_n(\sigma)$ en Cas 2 (théorie des problèmes inverses statistiques).
- **Algorithmes globaux** : EM multi-démarrages, méthodes spectrales (méthode des moments), algorithmes de descente sur variétés.
- **Extension 3D** : passage de $SO(2)$ à $SO(3)$, discrétisation sur la sphère.
- **Initialisation par méthode spectrale** pour briser le plateau algorithmique.


Merci pour votre attention.

Annexe Spectre de $A_z^\top A_z$ en Cas 2



Valeurs propres de $M^{(k)}$ pour le Cas 2. La décroissance en $|\xi|^{-1}$ illustre le mauvais conditionnement intrinsèque de l'opérateur de projection.

Annexe Erreur avec régularisation en Cas 2



Annexe Gradient et inégalité de Jensen (preuve de monotonie EM)

Soit $q(z) = p(Z|Y; \theta^{(k)})$. Par concavité de $\log$:

$$\log p(Y; \theta) = \log \int \frac{p(Y, Z; \theta)}{q(Z)} q(Z) d\mu(Z) \geq \int q(Z) \log \frac{p(Y, Z; \theta)}{q(Z)} d\mu(Z).$$

Donc $\ell_n(\theta) \geq Q(\theta|\theta^{(k)}) + C(\theta^{(k)})$, avec C indépendant de θ . Puisque $\theta^{(k+1)}$ maximise Q ,

$$\ell_n(\theta^{(k+1)}) \geq Q(\theta^{(k+1)}|\theta^{(k)}) + C(\theta^{(k)}) \geq Q(\theta^{(k)}|\theta^{(k)}) + C(\theta^{(k)}) = \ell_n(\theta^{(k)}).$$